

รายงานโครงงาน

การวิเคราะห์ข้อมูลการเจริญเติบโตของพืชเพาะเลี้ยงเนื้อเยื่อด้วยแบบจำลอง SAM3

ในระยะก่อนออกอนุบาล

ผู้จัดทำ: พิรณย์ ดั่งทอง

โรงเรียน: โรงเรียนวิทยาศาสตร์จุฬาภรณราชวิทยาลัย บุรีรัมย์

สาขา: คอมพิวเตอร์และชีววิทยา (CSBI)

ฉบับ: v1 (ร่างแรก) · วันที่: 17 สิงหาคม 2569

หมายเหตุสถานะภายใน: '[FACT]' = ตรวจแล้วจากข้อมูลจริง/paper จริง · '[PLAN]' = แผนการทดลอง ·

'[EXPECTED]' = ผลที่คาดว่าจะเกิด · '[RESULT]' = ผลการทดลองจริง · '[OPEN]' = รอข้อมูล/ต้องตัดสินใจ

เอกสารนี้เขียนตามคู่มือผู้นำการเขียนงานวิจัยภาษาไทย (Research Writing Adviser) — ห้ามอ้าง citation

ที่ยังไม่ตรวจถึง paper จริง

บทคัดย่อ

การเพาะเลี้ยงเนื้อเยื่อพืช (plant tissue culture) เป็นเทคโนโลยีหลักของการขยายพันธุ์พืชเชิงพาณิชย์ และการตัดสินใจว่าเมื่อใดจึงควรย้ายต้นออกอนุบาล (acclimatization)

ยังคงอาศัยการตรวจด้วยสายตาของนักวิทยาศาสตร์เป็นรายขวด ซึ่งเป็นคอขวดด้านแรงงานและเวลา และมีความแปรปรวนระหว่างผู้ประเมิน [FACT — Bethge et al., 2023; Murphy & Adelberg, 2024]

โครงงานนี้พัฒนาและประเมินระบบคัดกรองความพร้อมอนุบาลของต้นพืชเพาะเลี้ยงเนื้อเยื่อแบบไม่ทำลายตัวอย่าง (non-destructive) โดยใช้แบบจำลองพื้นฐาน Segment Anything Model 3 (SAM3)

ในโหมด Promptable Concept Segmentation (PCS) แบบ zero-shot

เพื่อแบ่งส่วนภาพต้นพืชผ่านขวดแก้วด้วยพรมบัพข้อความ 5 คำ ได้แก่ plant, leaf, shoot, stem และ root (ระบบรากเป็นตัวชี้วัดอันดับ 1 ของความพร้อมอนุบาล) จากนั้นคำนวณลักษณะเชิงปริมาณ 6 กลุ่ม (โครงสร้าง อวัยวะ ความซับซ้อน สี คุณภาพภาพ และการตัดสินใจ) และจัดกลุ่มขวดเป็น ยังไม่พร้อม / พร้อมอนุบาล / ตรวจเอง (ROI ไม่ชัดหรือหนาแน่นเกิน)

พร้อมคะแนนความมั่นใจและกลไกป้องกันความผิดพลาดเมื่อตรวจหาขอบเขตขวดไม่พบ

การทดลองกับภาพถ่ายจริง 100 ขวดพริกจินดา (รัน Colab 18 สิงหาคม 2569)
ให้ความสัมพันธ์ที่สมเหตุสมผลเชิงชีววิทยา ได้แก่ จำนวนใบกับพื้นที่ปกคลุม ($r = 0.760$)
พื้นที่ปกคลุมกับความสูง ($r = 0.716$) และสัดส่วนสีเขียวกับสุขภาพต้น ($r = 0.922$) [RESULT]
และจัดกลุ่ม verdict ได้ 13 ขวดพร้อมอนุบาล / 51 ขวดยังไม่พร้อม / 36 ขวด ROI-ไม่ชัด-ตรวจเอง
โดยประมวลผล 100 ขวดในเวลาประมาณ 15 นาที
งานนี้อยู่ในระหว่างการประเมินเปรียบเทียบกับวิธีพื้นฐาน (baseline: SAM2, YOLO-seg,
การแบ่งส่วนเชิงคลาสสิก) ด้วย mIoU/Dice
และการสร้างค่าอ้างอิงจากผู้ประเมินเพื่อตรวจสอบความถูกต้องของระบบ [PLAN]
คำสำคัญ: การเพาะเลี้ยงเนื้อเยื่อ, การวัดลักษณะปรากฏของพืชด้วยภาพ, การแบ่งส่วนภาพ, SAM3,
zero-shot, ชุดข้อมูล, การย้ายออกอนุบาล

บทที่ 1 บทนำ

1.1 ความเป็นมาและความสำคัญ

การเพาะเลี้ยงเนื้อเยื่อพืช (plant tissue culture) เป็นเทคโนโลยีการขยายพันธุ์ที่ใช้ชิ้นส่วนพืชขนาดเล็ก (explant) เพาะเลี้ยงในสภาพปลอดเชื้อบนอาหารสังเคราะห์

ถูกใช้อย่างกว้างขวางในเชิงพาณิชย์สำหรับพืชเกษตร อาหาร เภสัชกรรม และเครื่องสำอาง (Hasnain et al., 2022) สำหรับประเทศไทย

เทคโนโลยีนี้มีบทบาทสำคัญในอุตสาหกรรมกล้วยไม้ซึ่งเป็นสินค้าส่งออกหลักของประเทศ

ปัญหาสำคัญของกระบวนการนี้คือการตัดสินใจว่าเมื่อใดจึงควรย้ายต้นออกอนุบาล (acclimatization)

ซึ่งต้องพิจารณารายขวด ทุก 3–8 สัปดาห์ของรอบการขยายพันธุ์ ขึ้นกับชนิดพืช (Regni et al., 2025)

การตัดสินใจที่ช้าหรือเร็วเกินไป อาจทำให้เกิดความผิดปกติของเนื้อเยื่อ เช่น hyperhydricity

การตายของเนื้อเยื่อ และประสิทธิภาพการขยายพันธุ์ที่ลดลง [OPEN — ต้องเพิ่มหลักฐาน paper ที่ verify] ปัจจุบันการประเมินความพร้อมอนุบาลยังอาศัยการตรวจด้วยสายตาเป็นรายขวด

ซึ่งใช้แรงงานมากและมีค่าใช้จ่ายสูง โดยค่าแรงงานคิดเป็นร้อยละ 60–70 ของต้นทุนการผลิต (Bethge et al., 2023) และผลการตรวจมีความแปรปรวนระหว่างผู้ประเมิน (Nguyen et al., 2025; Zhang et al., 2026)

งานวิจัยด้านปัญญาประดิษฐ์ (artificial intelligence: AI) และคอมพิวเตอร์วิทัศน์ (computer vision) แสดงให้เห็นว่าแบบจำลองการเรียนรู้เชิงลึก (deep learning)

ช่วยวัดลักษณะของพืชจากภาพได้โดยไม่ทำลายตัวอย่าง ลดแรงงาน และให้ผลที่ทำซ้ำได้ (Murphy & Adelberg, 2024; Peters et al., 2023) โดยเฉพาะแบบจำลองพื้นฐาน (foundation model) กลุ่ม Segment Anything Model (SAM) ซึ่งแบ่งส่วนภาพแบบ zero-shot โดยไม่ต้องฝึกด้วยข้อมูลเฉพาะงาน

1.2 ปัญหาการวิจัย

ยังไม่มีระบบต้นทุ่นดำที่ใช้เพียงสมาร์ทโฟนถ่ายภาพขวดเพาะเลี้ยงแล้วระบุความพร้อมอนุบาลแบบข้ามชนิดพืช โดยไม่ต้องฝึกแบบจำลองใหม่สำหรับพืชแต่ละชนิด งานที่ใกล้เคียงที่สุดใช้ภาพถ่าย 3D จากสมาร์ทโฟนวัดพื้นที่ปกคลุมของต้นต่อขวดใน blackberry และ blueberry (Regni et al., 2025) แต่ยังไม่มีการใช้แบบจำลองพื้นฐาน zero-shot แบ่งส่วนภาพผ่านขวดแก้วโดยตรงเพื่อจัดกลุ่มความพร้อมอนุบาล

1.3 คำถามวิจัย

ด้วยภาพถ่ายเพียงภาพเดียว (single snapshot) เปรียบกับ SAM3 PCS แบบ zero-shot และขั้นตอนวิธีตัดสินใจแบบกฎ (rule-based triage) ระบบจะจัดกลุ่มความพร้อมอนุบาลของขวดเพาะเลี้ยงเนื้อเยื่อ (ยังไม่พร้อม / พร้อมอนุบาล / ตรวจสอบ) ได้ถูกต้องเพียงใด

1.4 วัตถุประสงค์

1. สร้างกระบวนการประมวลผลภาพ (pipeline) ที่แบ่งส่วนภาพต้นพืชผ่านขวดแก้วด้วย SAM3 แบบ zero-shot (พร้อมปี 5 คำ + การตรวจจับขวด ROI) และคำนวณลักษณะเชิงปริมาณการเจริญเติบโต
2. ปรับปรุงความถูกต้องของการวัด (ขอบเขตขวด การนับใบ การสอบเทียบหน่วย) ให้ดีกว่ารอบการทดลองที่ 1
3. สร้างชุดข้อมูลภาพถ่ายจริงผ่านขวดแก้ว (100 ขวด พริกจินดา) พร้อม metadata และการกำกับภาพโดยมนุษย์บางส่วน เพื่อใช้เป็นทรัพยากรเปิด
4. ประเมินเปรียบเทียบ SAM3 กับวิธีพื้นฐาน (SAM2, YOLO-seg, การแบ่งส่วนเชิงคลาสสิก) ด้วย mIoU/Dice/F1 และวิเคราะห์ความไวของพร้อมปีและเกณฑ์ [PLAN]

5. ตรวจสอบความถูกต้องของผลการจัดกลุ่ม 3 คลาสกับค่าอ้างอิงจากผู้ประเมิน เมื่อมีข้อมูลกำกับ
[OPEN]

1.5 สมมติฐาน

H₁: SAM3 PCS ที่ใช้พร้อมข้อมูล 5 คำ (plant, leaf, shoot, stem, root) สามารถแบ่งส่วนภาพต้นพืชเฉพาะเลี้ยงเนื้อเยื่อผ่านขวดแก้วภายใต้แสงสะท้อน (glare) ฟ้า และไอน้ำ ได้โดยมีค่าเฉลี่ย IoU ≥ 0.65 เมื่อเทียบกับผลการกำกับโดยมนุษย์ และสูงกว่า baseline (SAM2, YOLO-seg, classical) [EXPECTED — ยังต้องตรวจสอบกับค่าอ้างอิงจริง]

H₂: ลักษณะเชิงปริมาณที่วัดจากภาพ (เช่น จำนวน shoot พื้นที่ฉายภาพ สัดส่วนสีเขียว) มีความสัมพันธ์กับลักษณะการเจริญของต้นจริง อย่างน้อยในทิศทางที่สมเหตุผลเชิงชีววิทยา [RESULT บางส่วน — รอบ 1: $r = 0.853$ และ $r = -0.597$]

1.6 ขอบเขตของการศึกษา

- ภาพถ่ายขวดเพาะเลี้ยงเนื้อเยื่อชนิดปิด (ไม่เปิดฝา) จากห้องปฏิบัติการจริง
- ใช้แบบจำลอง SAM3 รุ่น facebook/sam3 ที่ต้องรันบน GPU ผ่าน Google Colab
- ผลลัพธ์เป็นเครื่องมือช่วยตัดสินใจ (decision-support) ไม่ใช่การวินิจฉัยขั้นสุดท้าย
- ชนิดพืชที่อยู่นอกตารางเกณฑ์เฉพาะชนิด ใช้ค่ากลางในการตัดสินใจ

บทที่ 2 เอกสารและงานวิจัยที่เกี่ยวข้อง

2.1 การเพาะเลี้ยงเนื้อเยื่อเกี่ยวกับการตัดสินใจย้ายออกอนุบาล

การพิจารณาย้ายต้นออกอนุบาลต้องทำทุก 3–8 สัปดาห์ของรอบการขยายพันธุ์ ขึ้นกับชนิดพืชและสูตรอาหาร (Regni et al., 2025)

การประเมินด้วยสายตาเป็นรายขวดมีความแปรปรวนระหว่างบุคคล

และการตรวจไม่ทั่วถึงเมื่อมีขวดหลายร้อยถึงหลายพันขวด (Murphy & Adelberg, 2024; Nguyen et al., 2025) งานที่พยายามวัดการเจริญในขวดแบบไม่เปิดฝา เช่น ระบบ Phenomenon

ใช้เซนเซอร์หลายชนิดร่วมกับ random forest วัดพื้นที่ฉายภาพและความสูงของเรือนยอด

แต่เป็นอุปกรณ์เฉพาะราคาสูง (Bethge et al., 2023) [FACT]

2.2 การวัดลักษณะปรากฏของพืชด้วยภาพและการประยุกต์ AI

การวัดลักษณะปรากฏของพืชด้วยภาพ (image-based phenotyping) ช่วยลดแรงงาน
ลดข้อผิดพลาดจากคน และติดตามต้นเดิมซ้ำ ๆ ได้โดยไม่ทำลายตัวอย่าง (Murphy & Adelberg, 2024)
แบบจำลอง AI ให้ความสม่ำเสมอภายในสูงกว่าระดับผู้ประเมินคนเดียว และลดความลำเอียงของผู้ตรวจ
(Zhang et al., 2026; Peters et al., 2023)
งานประเมินการเจริญของหัวมันฝรั่งขนาดเล็กในสภาพเพาะเลี้ยงเนื้อเยื่อด้วยภาพดิจิทัล
แสดงความเป็นไปได้ของการใช้ AI ในขั้นตอนเพาะเลี้ยงเนื้อเยื่อโดยตรง (Diningrat et al., 2024)
[FACT]

2.3 แบบจำลองพื้นฐานสำหรับการแบ่งส่วนภาพ: SAM, SAM2, SAM3

ตระกูล Segment Anything Model เป็นแบบจำลองพื้นฐานสำหรับการแบ่งส่วนภาพแยกวัตถุ
(instance segmentation) แบบเปิดคำศัพท์ (open-vocabulary) SAM3 (Carion et al., 2025)
เพิ่มความสามารถ Promptable Concept Segmentation (PCS)
คือแบ่งส่วนภาพทุกวัตถุที่ตรงกับแนวคิดที่ระบุเป็นข้อความสั้นได้ครบทุก instance และมี presence
token ช่วยแยกแนวคิดที่ใกล้เคียงกัน โครงสร้างเป็น detector (แบบ DETR) ร่วมกับ tracker
ที่ใช้สถาปัตยกรรมของ SAM2 จำนวนพารามิเตอร์ 848 ล้านตัว ประเมินบนชุดข้อมูล SA-Co ที่มีแนวคิด
270,000 รายการ ได้ผลประมาณร้อยละ 75–80 ของประสิทธิภาพมนุษย์ [FACT — Carion et al.,
2025]

หลักฐานอิสระล่าสุดจากงาน phenotyping พืชในโรงเรือนควบคุม (ข้าวโพด ฝ้าย ข้าว ข้าวฟ่าง มากกว่า
50,000 ภาพ) ระบุว่าเมื่อเปรียบเทียบ BEN v2, BiRefNet, SAM v2.1, SAM3, YOLOv11 และ
YOLOv12 SAM3 ให้ความแม่นยำสูงสุดและสม่ำเสมอที่สุดข้ามโครงสร้างพืชที่หลากหลาย
โดยใช้ในโหมดไม่มีตัวตรวจจับ (detector-free) ด้วยพรมอบข้อความ "plant" โดยตรง
ซึ่งเป็นแนวทางเดียวกับโครงงานนี้ แม้ต้องใช้เวลาคำนวณมากกว่าแบบจำลองแบบคลาสสิก (Orvati Nia
et al., 2026) [FACT]

ในตระกูลเดียวกัน งาน Segment Any Plant (SAP) ใช้ SAM2 แบบ few-shot ที่ไม่ต้องฝึกใหม่
วัดการเจริญของต้น Arabidopsis ราก และทานตะวันตามเวลา ได้ค่าเฉลี่ย IoU 0.89–0.93
จากการขึ้นาเฟรมเดียว (Abbey & Meroz, 2026) [FACT] งาน zero-shot แบบผสม Grounding
DINO + SAM ในฟาร์มแนวตั้งก็ยืนยันแนวโน้มเดียวกัน (Bao et al., 2025)

2.4 ช่องว่างของงานวิจัย

แม้มีงานใช้ SAM/SAM2 กับพืชหลายงาน แต่ยังไม่มีการใช้ (1)

แบ่งส่วนภาพต้นพืชเฉพาะเลี้ยงเนื้อเยื่อผ่านขวดแก้วที่มีแสงสะท้อนและไอน้ำโดยตรงด้วยแบบจำลอง zero-shot และ (2)

ต่อยอดเป็นระบบช่วยตัดสินใจจัดกลุ่มความพร้อมอนุบาลแบบข้ามชนิดพืชโดยไม่ต้องฝึกใหม่ งานของ Regni et al. (2025) วัดพื้นที่ปกคลุมต่อขวดด้วยภาพ 3D

แต่จำกัดชนิดพืชและยังไม่เป็นระบบจัดกลุ่มความพร้อมอนุบาล [FACT — จากงานวิจัยที่พบ]

2.5 ความสามารถในการทำซ้ำด้วย Google Colab

การใช้ Google Colab พร้อมกับการเผยแพร่ notebook เป็นแนวทางที่งานวิจัยด้านชีววิทยาพืชใช้จริง เช่น การแบ่งส่วนภาพราก/ดินทั้งกระบวนการบน Colab (Rippner et al., 2022) และแพลตฟอร์ม ZeroCostDL4Mic ที่รันการฝึกแบบจำลองการแบ่งส่วนภาพบน Colab โดยไม่ต้องซื้อ GPU (von Chamier et al., 2021) สนับสนุนความสามารถในการทำซ้ำของโครงการนี้ [FACT]

บทที่ 3 วิธีดำเนินการ

3.1 ภาพรวมกระบวนการประมวลผลภาพ (pipeline)

กระบวนการประมวลผลภาพประกอบด้วย 5 ขั้นตอน: (1) เตรียมภาพและกำหนดขอบเขตขวด (ROI) (2) แบ่งส่วนภาพด้วย SAM3 โดยใช้พรม 5 คำ (3) คำนวณลักษณะเชิงปริมาณ (4) ตัดสินใจแบบกฎ 3 คลาสพร้อมคะแนนความมั่นใจ (5) ส่งออกผลเป็น CSV/XLSX กราฟ และรายงาน HTML

3.2 ข้อมูลภาพ

รอบที่ 1 (ผลจริงแล้ว): ภาพถ่ายขวดเพาะเลี้ยงเนื้อเยื่อ 51 ขวด 4 ชนิดพืช

ถ่ายในห้องปฏิบัติการจริงเมื่อวันที่ 16 กรกฎาคม 2569 ภายใต้เงื่อนไขจริงที่มีแสงสะท้อน ฝ้า และไอน้ำบนขวดแก้ว [RESULT — ตามบันทึก DEV_LOG]

รอบที่ 2 (แผน): ชุดภาพใหม่หลายชนิดพืชและหลายช่วงอายุ จำนวนเป้าหมาย 100 ขวดขึ้นไป [PLAN]

สถานะข้อมูล: [OPEN — รอเส้นทางชุดภาพจากผู้จัดทำ]

3.3 การแบ่งส่วนภาพด้วย SAM3

- แบบจำลอง: facebook/sam3 (gated, ต้องยืนยันสิทธิ์ผ่าน Hugging Face) รันบน GPU (Colab T4) [FACT — Carion et al., 2025]

- พรอมป์ข้อความ 5 คำ: plant, leaf, shoot, stem, root
- เปิดการตรวจจับขอบ (glass jar bottle) เพื่อกำหนดขอบเขตขวดเป็น ROI แล้วคำนวณพื้นที่ปกคลุมสัมพัทธ์กับขวด (coverage_ratio)
- ค่าเกณฑ์: score ≥ 0.5 และ mask ≥ 0.5

3.4 การคำนวณลักษณะเชิงปริมาณ (feature)

กลุ่ม	ตัวอย่างตัวแปร
โครงสร้าง	พื้นที่ฉายภาพ (projected area), ความสูง/ความกว้างโดยประมาณ, coverage_ratio เทียบขวด
อวัยวะ	จำนวน shoot, จำนวนใบ (นับแบบ merged ลดการแบ่งเกิน), จำนวน stem, จำนวน root
ความซับซ้อน	hull_ratio (ความซับซ้อนของรูปร่าง)
สี	สัดส่วนพิกเซลเขียว/เหลือง/น้ำตาล (HSV)
คุณภาพภาพ	คะแนนแสงสะท้อน (glare) และไอน้ำ (condensation)
การตัดสินใจ	คลาส verdict + คะแนนความมั่นใจ

นิยามตัวแปรตรึงไว้ในเอกสาร 'research/_orchestration.md' [FACT — เอกสารโปรเจกต์]

3.5 การตัดสินใจแบบกฎ (rule-based verdict)

จัดกลุ่ม 3 คลาสจาก coverage_ratio เทียบเกณฑ์: ค่าเกณฑ์กลาง (generic) ready = 0.20 (พริกจินดา ตั้งตามผู้เชี่ยวชาญ 2026-08-18) และ overdense = 0.80 เป็นค่าโดยประมาณจากวรรณกรรมข้ามชนิด ยังไม่ผ่านการสอบเทียบ (calibration) กับห้องปฏิบัติการจริง [FACT — ข้อจำกัด] ชนิดที่มีข้อมูลเฉพาะใช้ตาราง SPECIES_THRESHOLDS [OPEN — ยังไม่เปิดใช้งาน เนื่องจากยังไม่มีข้อมูลจริงต่อชนิด]

3.6 การวิเคราะห์ข้อมูล

- ตรวจสอบความสัมพันธ์ระหว่างตัวแปรด้วยสัมประสิทธิ์สหสัมพันธ์เพียร์สัน (Pearson correlation)
- เมื่อมีค่าอ้างอิงจากผู้ประเมิน (ground truth) จะคำนวณ IoU/Dice สำหรับมาสก์ และ MAE/RMSE สำหรับการวัดเชิงปริมาณ [PLAN]
- การสอบเทียบหน่วยพิกเซลเป็นเซนติเมตร (PIXEL_TO_CM) ยังไม่ดำเนินการ [OPEN — ตามคู่มือ CALIBRATION_GUIDE]

- การเปรียบเทียบ baseline: รัน SAM2, YOLO-seg

และการแบ่งส่วนเชิงคลาสสิกบนชุดภาพเดียวกัน เปรียบเทียบ mIoU/Dice/F1 และเวลาประมวลผล [PLAN — อ้างอิงเกณฑ์จาก Orvati Nia et al., 2026]

- การวิเคราะห์ความไว: ทดสอบชุดพรมบัพทางเลือก (prompt sensitivity) และช่วงเกณฑ์ ready/overdense (threshold sensitivity) แล้วรายงานความแปรปรวนของผล [PLAN — อ้างอิง Dubois et al., 2026]

3.7 การรันบน Google Colab

รันเป็นสคริปต์ headless บน Colab ด้วยคำสั่ง ``python sam3_growth_pipeline.py --data <โฟลเดอร์ภาพ> --out <โฟลเดอร์ผลลัพธ์>`` ผลลัพธ์เป็น plant_growth_summary.csv/.xlsx, โฟลเดอร์ overlays/, plots/ และ report.html [FACT — โค้ดใน src/sam3_growth_pipeline.py ผ่านการทดสอบการคอมไพล์และฟังก์ชันคณิตศาสตร์]

บทที่ 4 ผลการทดลอง

4.1 การทดสอบการทำงานของโค้ด (synthetic test)

ทดสอบฟังก์ชันคำนวณลักษณะและหน่วยวัดบนภาพจำลองที่รู้ค่าจริง: การแยกชิ้นส่วนติดกัน/แยกกัน การนับใบแบบ fallback และการสร้างรายงาน สร้างผลครบทุกส่วน [RESULT — ผ่าน, ตาม DEV_LOG 7 ส.ค. 2569] ตัวเลข IoU/Dice จากภาพจำลองนี้ (เช่น 1.0 / 0.0 / 0.533) เป็นการทดสอบโค้ด ไม่ใช่ผลการแบ่งส่วนภาพจริงบนข้อมูลพืช

4.2 การทดลองรอบที่ 1 — ภาพจริง 51 ชุด [RESULT]

รัน SAM3 บนภาพ 51 ชุด ได้ตารางสรุป 40 คอลัมน์ต่อภาพ ตรวจสอบความสมเหตุสมผลเชิงชีววิทยา:

การตรวจ	ผล	การตีความ
จำนวน shoot ↔ ความสูงของต้น	$r = 0.853$	ต้นที่สูงกว่ามีจำนวนหน่อมากกว่า — สอดคล้องกับความคาดหวังทางชีววิทยา
สัดส่วนสีเขียว ↔ สัดส่วนสีเหลือง	$r = -0.597$	ต้นที่เขียวมากมีส่วนเหลืองน้อย — สอดคล้องกับสถานะสุขภาพต้น

ข้อบกพร่องที่พบ: (1) การกำหนด ROI ทั้งภาพทำให้ค่า coverage ลำเอียง (2) จำนวนใบ (leaf_count) เป็น 0 บนภาพที่มีต้น (3) การแบ่งส่วนเกิน (over-segmentation) ทำให้อวัยวะขึ้นเดียวกันถูกนับแยก

4.3 การปรับปรุงรอบที่ 2

แก้ไขข้อบกพร่องโดย: เปิด DETECT_BOTTLE เพื่อใช้ขวดเป็น ROI, นับใบแบบ merged และเพิ่ม fallback การนับใบจาก plant+shoot, ปรับฟอนต์ไทยในกราฟ [FACT — โค้ดผ่านการทดสอบแล้ว ยังไม่รันกับภาพชุดจริงชุดใหม่]

4.4 การทดลองรอบที่ 2 — ภาพจริง 100 ขวด พริกจินดา [RESULT]

รัน pipeline รอบที่ 2 (เปิด DETECT_BOTTLE + นับใบแบบ merged + verdict กัน ROI ไม่ซ้ำ)
บนชุดภาพจริง 100 ขวดพริกจินดา (รัน Colab T4, 18 สิงหาคม 2569) ได้ผลดังนี้

ผลการจัดกลุ่ม verdict (100 ขวด):

กลุ่ม	จำนวนขวด
พร้อมอนุบาล	13
ยังไม่พร้อม (wait)	51
ROI-ไม่ซ้ำ-ตรวจเอง	36

ความสัมพันธ์เชิงปริมาณ (Pearson r):

คู่ตัวแปร	r
leaf_count ↔ coverage_ratio	0.760
coverage_ratio ↔ height_proxy	0.716
green_pct ↔ healthy_color	0.922
leaf_count ↔ shoot_count	0.538
coverage_ratio ↔ total_area_px	0.932

ทุกคู่เป็นบวกและสมเหตุผลเชิงชีววิทยา — ใบมากสัมพันธ์กับพื้นที่ปกคลุมมาก

และสัดส่วนสีเขียวสัมพันธ์กับสุขภาพต้น [RESULT — ตามบันทึก DEV_LOG 18–19 ส.ค. 2569]

เวลาประมวลผลรวม 100 ขวดประมาณ 15 นาที

ข้อบกพร่องที่พบ: 36 ขวด (36%) ที่ SAM3 ตรวจหาขวด (ROI) ไม่พบ ทำให้ต้องส่งให้นักวิจัยตรวจ —
ต้องปรับปรุงการตรวจจับขวดในรอบถัดไป [OPEN — งานค้าง]

บทที่ 5 การอภิปรายผล

ผลการทดลองรอบที่ 1 (51 ขวด) และรอบที่ 2 (100 ขวด พริกจินดา)

ให้ความสัมพันธ์ของลักษณะเชิงปริมาณที่สมเหตุผลเชิงชีววิทยา ทั้งจำนวน shoot กับความสูง (รอบ 1: $r = 0.853$) และจำนวนใบกับพื้นที่ปกคลุม (รอบ 2: $r = 0.760$) รวมถึงสัดส่วนสีเขียวกับสุขภาพต้น ($r =$

0.922) อย่างไรก็ตาม ผลนี้เป็นการตรวจความสมเหตุสมผลเบื้องต้น (sanity check) บนข้อมูลจริง
ยังไม่ใช่การตรวจสอบความถูกต้อง (validation) เทียบกับค่าอ้างอิงจากผู้ประเมิน
และยังไม่ได้สอบเทียบหน่วยเป็นเซนติเมตร

ประเด็นที่ต้องแก้ไขมากที่สุดคือ 36% ของขวดที่ระบบตรวจหาขวด (ROI) ไม่พบและส่งให้นักวิจัยตรวจ
— แม็กโลนี้ช่วยป้องกันการให้ผลผิดพลาดได้ แต่สัดส่วนที่สูงบ่งชี้ว่าการตรวจจับขวดต้องปรับปรุง (เช่น
การปรับเกณฑ์หรือการเทรนตัวตรวจจับขวดเฉพาะ) ก่อนนำไปใช้จริง

ข้อสังเกตด้านความไวของพรอมป์: งานวิจัยล่าสุดพบว่าการแบ่งส่วนภาพด้วย SAM3

แบบชี้นำด้วยข้อความมีประสิทธิภาพสูงแต่ไวต่อถ้อยคำพรอมป์ (prompt-sensitive) (Dubois et al.,
2026) ดังนั้นผลลัพธ์ของระบบขึ้นกับการออกแบบพรอมป์

จึงต้องทดสอบชุดพรอมป์ทางเลือกและรายงานความแปรปรวนของผล รวมถึงเปรียบเทียบกับวิธีพื้นฐาน
(baseline) เพื่อยืนยันว่าการใช้ SAM3 ให้ผลดีกว่าวิธีอื่นอย่างมีนัยสำคัญ

ผลงานของ Orvati Nia et al. (2026) สนับสนุนว่าการใช้ SAM3 แบบไม่มีตัวตรวจจับด้วยพรอมป์

"plant" ให้ความแม่นยำสูงข้ามชนิดพืช แม้แลกกับเวลาดำเนินการที่มากขึ้น

ซึ่งสอดคล้องกับข้อจำกัดด้านทรัพยากรของโครงการนี้ที่ต้องพึ่ง GPU บน Colab

บทที่ 6 สรุปและข้อเสนอแนะ

6.1 สรุป

โครงการได้สร้างกระบวนการประมวลผลภาพเพื่อการเจริญของพืชเพาะเลี้ยงเนื้อเยื่อผ่านขวดแก้วด้วย

SAM3 แบบ zero-shot ผลรอบที่ 1 ยืนยันความเป็นไปได้ (feasibility)

และให้ความสัมพันธ์ของตัวแปรที่สมเหตุสมผลเชิงชีววิทยา

แต่ยังต้องปรับปรุงการวัดและตรวจสอบกับค่าอ้างอิงจริงก่อนนำไปใช้

6.2 ข้อเสนอแนะ

1. รันการทดลองชุดภาพใหม่ (หลายชนิด หลายช่วงอายุ) แล้วเปรียบเทียบผลกับรอบที่ 1–2
2. ปรับปรุงการตรวจจับขวด (ROI) เพื่อลดสัดส่วนขวด "ROI-ไม่ชัด-ตรวจเอง" (36% ในรอบที่ 2)
3. สอบเทียบหน่วยพิกเซลเป็นเซนติเมตรกับขวดจริง (PIXEL_TO_CM)
4. สร้างค่าอ้างอิงจากผู้ประเมินหลายคน (ground truth) แล้วคำนวณ IoU/Dice, MAE/RMSE และ confusion matrix ของ verdict

5. ประเมินเปรียบเทียบ SAM3 กับ baseline (SAM2, YOLO-seg, classical) และวิเคราะห์ความไวของพารามิเตอร์และเกณฑ์
6. เปิดใช้เกณฑ์เฉพาะชนิดพืชเมื่อมีข้อมูลจริงต่อชนิด
7. ตรวจสอบใบอนุญาตของ SAM3 (SAM License) ก่อนนำเสนอหรือตีพิมพ์
8. จัดทำชุดข้อมูลพร้อมเอกสารกำกับตามหลัก FAIR เพื่อความสามารถในการทำซ้ำ

บรรณานุกรม (APA 7)

เฉพาะงานที่ถูกอ้างในเนื้อหา ทุกตัวตรวจถึง paper จริงและ DOI/URL ที่เข้าถึงได้ ตามกฎ citation ของโครงการ (งานอายุไม่เกิน 5 ปี)

- Bethge, H., Winkelmann, T., Lüdeke, P., & Rath, T. (2023). Low-cost and automated phenotyping system "Phenomenon" for multi-sensor in situ monitoring in plant in vitro culture. *Plant Methods*, 19, Article 42. <https://doi.org/10.1186/s13007-023-01018-w>
- Carion, N., Gustafson, L., Hu, Y.-T., Debnath, S., Hu, R., Suris, D., Ryali, C., Alwade, K. V., Khedr, H., Huang, A., Lei, J., Ma, T., Guo, B., Kalla, A., Marks, M., Greer, J., Wang, M., Sun, P., Rädle, R., ... Feichtenhofer, C. (2025). *SAM 3: Segment anything with concepts* (arXiv:2511.16719). arXiv. <https://arxiv.org/abs/2511.16719>
- Bao, Q.-Z., Yang, Y.-X., Li, Q., & Yang, H.-C. (2025). Zero-shot instance segmentation for plant phenotyping in vertical farming with foundation models and VC-NMS. *Frontiers in Plant Science*, 16, Article 1536226. <https://doi.org/10.3389/fpls.2025.1536226>
- Diningrat, D. S., et al. (2024). Design of artificial intelligence for evaluation of in vitro potato (*Solanum tuberosum*) microtuber growth from tissue culture based on digital imagery. *Journal of Physics: Conference Series*, 2908, Article 012001. <https://doi.org/10.1088/1742-6596/2908/1/012001>
- Dubois, R., Bousset, L., Jumel, S., Leclerc, M., Parisey, N., & Joly, A. (2026). *Text guidance is powerful but prompt-sensitive for weakly-supervised leaf symptom segmentation* (preprint). bioRxiv. <https://doi.org/10.64898/2026.07.10.737680>

- Abbey, A., & Meroz, Y. (2026). *Segment any plant (SAP): Foundation-model segmentation for plant time-series phenotyping* (preprint). bioRxiv.
<https://doi.org/10.64898/2026.03.11.711099>
- Hasnain, A., Naqvi, S. A. H., Ayesha, S. I., Khalid, F., Ellahi, M., Iqbal, S., Hassan, M. Z., Abbas, A., Adamski, R., Markowska, D., Baazeem, A., Mustafa, G., Moustafa, M., Hasan, M. E., & Abdelhamid, M. M. A. (2022). Plants in vitro propagation with its applications in food, pharmaceuticals and cosmetic industries; current scenario and future approaches. *Frontiers in Plant Science*, 13, Article 1009395.
<https://doi.org/10.3389/fpls.2022.1009395>
- Murphy, K. M., & Adelberg, J. W. (2024). Image-based high-throughput phenotyping: A review of the state of the art and future directions for plant biology. *Annual Review of Plant Biology*, 75, 771–794. <https://doi.org/10.1146/annurev-arplant-070523-042828>
- Nguyen, T. H., et al. (2025). High-throughput phenotyping for plant breeding: Advances and challenges. *Plants*, 14(6), Article 907. <https://doi.org/10.3390/plants14060907>
- Orvati Nia, F., Peeples, J., Murray, S. C., McFarland, A., Vann, T., Salehi, S., Hardin, R., Baltensperger, D. D., Ibrahim, A. M. H., Thomasson, J. A., Fadamiro, H., Subramanian, N. K., Pillai, S. D., Roston, R., Ishimwe, J., Basak, D., Oladepo, N., & Vysyaraju, U. (2026). A data-driven image extraction and analysis pipeline for plant phenotyping in controlled environments (preprint). bioRxiv. <https://doi.org/10.64898/2026.02.25.707797>
- Peters, R., et al. (2023). A CNN-based approach for root segmentation comparable to human experts. *Scientific Reports*, 13, Article 28400. <https://doi.org/10.1038/s41598-023-28400-x>
- Regni, L., et al. (2025). Micropropagation of blackberry and blueberry: Assessing the effects of subculture duration and explant density through the integration of traditional measurements and smartphone 3D imaging. *Plant Cell, Tissue and Organ Culture*.
<https://doi.org/10.1007/s11240-025-03267-0> [OPEN — ตรวจสอบชื่อผู้แต่งครบก่อนยื่น]

Rippner, D. A., et al. (2022). Automatic root and soil segmentation from X-ray computed tomography using a fully convolutional network and Google Colab. *Frontiers in Plant Science*, 13, Article 893140. <https://doi.org/10.3389/fpls.2022.893140>

von Chamier, L., Lahnemann, D., et al. (2021). Democratising deep learning for microscopy with ZeroCostDL4Mic. *Nature Communications*, 12, Article 2276. <https://doi.org/10.1038/s41467-021-22518-0>

Zhang, Y., et al. (2026). Observer bias in phenotypic assessment and the consistency of AI-based evaluation. *Scientific Data*, 13(1). <https://doi.org/10.1038/s41597-026-06926-9>

สถานะเอกสาร: v1 ร่างแรก — เนื้อหาส่วนผลการทดลองชุดใหม่รอข้อมูลจริง [OPEN] · การตรวจภาษา 3 รอบ (ตามคู่มือ ระยะที่ 4) ดำเนินการแล้ว 2026-08-25 (รอบที่ 1-3) · รูป/flowchart ยังไม่แทรก [ผู้จัดทำจัดทำภายหลัง]

งานค้างก่อนยื่น (ตามกฎ citation)

- ☐ ตรวจชื่อผู้แต่งเต็ม (แทน et al.) ให้ครบ: Diningrat 2024, Nguyen 2025, Peters 2023, Regni 2025, Rippner 2022, Zhang 2026 (ดูไฟล์ `research/citations\_\*.md`)
- ☒ ตรวจภาษา 3 รอบ (คู่มือ ระยะที่ 4) — แก้ภาษาแล้ว 2026-08-25 (รอบที่ 1-3)
- ☐ ตรวจ render ใน Microsoft Word
- ☐ แทรกรูป/flowchart จริง [ผู้จัดทำจัดทำภายหลัง]
- ☐ เพิ่มผลการทดลองชุดภาพใหม่หลังรัน Colab [รอข้อมูล]